

调研报告

1.引言

图像去模糊旨在从退化观测中恢复清晰图像，是计算机视觉中的一项基础而关键的低层视觉任务。近年来，基于深度学习的方法，尤其是基于编码器-解码器结构的卷积神经网络（CNN），在图像去模糊领域取得了显著进展。

然而，由于卷积算子具有局部性和空间不变性，CNN 在捕捉非局部上下文信息及长距离像素依赖方面存在固有限制^[1,2]。部分研究尝试通过加深网络或扩大感受野^[3]来缓解这一问题，但往往伴随着计算复杂度的显著增加。

为突破上述局限，Transformer 被引入图像去模糊任务^[4-7]。其基于自注意力机制的全局建模能力在复杂结构恢复方面展现出优势。然而，为了平衡计算效率，现有主流方法中的注意力机制通常被限制在矩形窗口或特定轴向（如水平与垂直方向）上进行计算，隐含假设运动模糊方向主要遵循正交方向分布。而真实场景中的运动模糊往往更加复杂且不规则^[8]。

从成像机理角度来看，运动模糊可被视为清晰图像与由运动轨迹决定的点扩散函数（PSF）的卷积退化过程^[9]，其在频域中表现为对特定方向和频率成分的系统性衰减。然而，现有频域去模糊方法^[10-12]多基于笛卡尔坐标系建模，使方向信息与频率幅值耦合在二维平面中，增加了对模糊几何结构的建模难度。

实际上，在频域中，模糊的方向性与强度分别对应于角向与径向频率分布特征。极坐标频域表示能够天然地解耦方向信息与频率尺度，为刻画运动模糊的几何结构提供更合适的表示空间。因此，本文探索基于频域极坐标表示的图像去模糊方法，有望从表示层面弥补现有空域及笛卡尔频域方法在方向建模方面的不足。

2.相关工作

2.1 空域驱动的深度图像去模糊方法

早期深度学习图像去模糊方法主要在空间域内展开。基于 CNN 的方法通过局部卷积特征建模，并从两阶段核估计^[13,14]逐步发展为多尺度^[15-17]、多阶段^[18-20]的端到端去模糊框架。

针对堆叠式多尺度网络计算成本高的问题，Cho 等人^[17]提出了 MIMO-UNet，

通过单编码器-单解码器结构实现多尺度输入与多尺度输出，并利用非对称特征融合模块高效地实现了由粗到精的去模糊策略。为缓解感受野受限的问题，Ruan 等人^[21,22]提出 LaKDNet，引入大核深度卷积与空间-通道混合机制，通过大幅提升有效感受野来模拟 Transformer 的全局建模能力，在保持轻量级架构的同时实现了高效去模糊。为进一步降低网络内部的系统复杂度，Chen 等人^[23]提出 NAFnet，验证了非线性激活函数在图像复原中的非必要性，通过设计乘法门控和简化通道注意力替代了传统的非线性操作，不仅大幅提升了计算效率，还在多项去模糊基准上取得了最先进的性能。

为进一步增强全局上下文建模能力，后续工作将 Transformer 引入空域去模糊任务，利用自注意力机制建模长距离像素依赖。IPT^[6]采用多头多尾的架构共享 Transformer 主体，通过大规模大规模监督与对比学习预训练验证了 Transformer 在低层视觉任务中的有效性。Tsai 等人^[24]提出 Stripformer，引入高效的条带式自注意力机制，通过水平与垂直维度的特征重加权，在降低计算量的同时显式建模了方向相关的模糊模式。Kuo 等人^[5]提出了 Concertormer，将注意力分解为局部捕捉细节的分量和全局信息聚合分量，并配合跨维度通信模块，在保持线性计算复杂度的同时实现了对空间与通道信息的全方位交互。

2.2 频域与多域联合建模的去模糊方法

频域作为图像的重要表示形式，近年来被广泛引入深度网络以解决各类任务^[25-31]。为了突破单一空域建模的局限，研究者开始探索频域与多域联合建模的方法，旨在利用不同变换域的特性互补来提升去模糊性能。多项工作将傅里叶变换嵌入网络结构，实现频域与空域的联合建模^[32,33,16]，或结合 Transformer 利用频域特性捕捉非局部依赖^[11,10]。

针对 CNN 处理低频全局信息的不足，Mao 等人^[33]提出 DeepRFT 框架。设计了一种残差快速傅里叶变换模块，利用 FFT 赋予网络捕捉长距离依赖和全频段信息的能力。在此基础上，该团队进一步挖掘频域操作的物理意义^[32]，发现在频域特征上直接应用 ReLU 激活函数可以隐式地捕捉模糊核的模式，并在基线上取得了显著的性能提升。Dong 等人^[16]提出了 MRLPFNet，利用自注意力机制作为可学习的低通滤波器来替代简单的频域操作，从而自适应地恢复空间变化的全局低频结构，还引入了小波变换作为特征融合。

针对 Transformer 自注意力机制二次方计算复杂度的问题，Kong 等人^[10]提出 FFTformer，利用卷积定理将空域中高昂的矩阵乘法转化为频域中高效的逐元素乘法，将复杂度降低至对数线性级别。EVSSM^[11]改用线性复杂度的 SSM 框架建模非局部信息，还提出高效判别式频域前馈网络，通过将频域筛选操作移至前馈网络的末端，有效规避了中间层特征通道膨胀带来的 FFT 变换开销。

另一类方法则将频域信息作为先验或辅助分支^[34,35]，引导空域特征学习。Lv 等人^[35]将傅里叶先验嵌入预训练扩散模型，利用傅里叶域中亮度与结构的特性，实现零样本场景下的联合低光增强与去模糊。Zhu^[36]等人分析模糊视频序列在傅里叶域中的频率-时间分布特性，提取频域先验以辅助空域时序建模。Gao 等人^[37]引入了一种可学习的二维离散小波变换构建频率域感知模块，结合多尺度网络架构，实现对图像高频细节与模糊方向特征的精准捕捉。

尽管上述方法在一定程度上利用了频域信息，但尚未充分探索在频域表示层面对模糊方向与强度进行系统建模的可能性。

2.3 方向感知的去模糊方法

为更好地刻画图像特征的空间分布与方向特性，一系列研究显式引入方向感知机制以提升模型性能^[24,38-42]。针对真实场景中运动模糊的空间非均匀性与方向复杂性，研究者尝试在网络中嵌入对运动方向的显式建模^[43-45]。Liu 等人^[43]提出运动自适应可分离协同滤波框架 MISC，通过估计像素级的运动流，将模糊特征沿预测的运动方向进行对齐，实现空间自适应的运动方向精准建模。Fang 等人^[44]从模糊核的角度出发，提出 UFPNet，利用归一化流在潜在空间中对非均匀模糊核进行建模，并引入不确定性学习以提升模型对空间变化模糊模式的感知鲁棒性。Chen 等人^[45]针对复杂的旋转运动提出 MDT 模型，通过极坐标分支捕捉旋转运动分量、笛卡尔卷积分支捕捉平移运动分量，实现了精细化的运动矢量分解。

然而，尽管上述方法通过流对齐、核建模或坐标系变换在一定程度上增强了方向感知能力，但其本质仍主要依赖于空域内的特征变换。未能在信号处理的底层表示上充分利用频域中方向（相位）与强度（幅度）天然分离的特性，限制了模型实现频率强度与模糊方向的解耦，导致在处理大尺度运动或高频方向纹理时仍有提升空间。

2.4 基于物理先验的模糊建模

针对局部运动模糊中轨迹难以建模的问题，Fang 等人^[46]提出了参数化模糊核的概念，将复杂的运动模糊分解为长度、角度和曲率三个物理参数，设计 Mamba 分支网络来充分利用这些显式的物理几何先验，在去模糊的同时有效保护了清晰背景。Ji 等人^[47]发现快门的曝光机制产生的模糊具有行依赖的物理特性，即模糊程度随图像行数变化，他们提出 RSS-T 模块利用水平窗口划分进行空间补偿，并引入频谱增强机制来捕捉频域中的全局物理上下文，从而实现高效去模糊。针对大幅度运动模糊的物理尺度挑战。Ruan 等人^[22]强调了网络有效感受野（ERF）与物理模糊轨迹尺度的匹配性。通过引入大核卷积，显著提升了网络对长距离物理像素依赖的捕捉能力，从而更有效地复原大尺度运动模糊。

上述研究共同揭示了将物理先验融入深度学习框架的巨大潜力。通过对模糊的参数化几何结构、成像系统的物理特性，或是网络感受野与模糊尺度的物理匹配性进行显式建模，这些方法能够更精准地约束网络的解空间，从而在处理特定类型的复杂模糊时取得优于通用模型的效果。

3. 公开数据集

本章介绍图像去模糊领域中常用的公开数据集，包括真实场景数据集 RealBlur^[48]，HIDE^[49]，RSblur^[50]，合成数据集 GoPro^[51]，其中 RealBlur-R 为 RAW 格式。上述数据集均提供模糊–清晰图像对，被广泛用于模型训练与性能评估。

3.1 GoPro

GoPro 数据集是图像去模糊任务中最常用的合成数据集之一。该数据集包含 3,214 对分辨率为 1,280×720 的模糊–清晰图像，其中 2,103 对用于训练，1,111 对用于测试。数据集通过高速摄像机拍摄视频序列，并对连续帧进行平均生成模糊图像，因此虽然模糊与清晰图像一一对应，但其模糊过程本质上仍为合成。

3.2 HIDE

HIDE 数据集主要面向动态场景下的图像去模糊问题，涵盖由相机抖动和物体运动引起的多种复杂模糊类型。该数据集包含 8,422 对模糊–清晰图像，以及 65,784 个密集标注的前景人体边界框。其中，训练集包含 6,397 对图像，测试集包含 2,025 对图像。相比 GoPro，HIDE 数据集在真实运动场景和动态模糊建模

方面更具挑战性。

3.3 Realblur

RealBlur 是一个基于真实成像过程构建的图像去模糊数据集，由 232 个不同场景的 4,738 对模糊—清晰图像组成。所有图像均以相机原始格式 (RAW) 和 JPEG 格式采集，从而形成 RealBlur-R (RAW) 和 RealBlur-J (JPEG) 两个子集。每个子集包含 3,758 对训练图像和 980 对测试图像。为保证评估准确性，数据集采用基于增强相关系数的单应性估计方法对去模糊结果与对应清晰图像进行对齐，并在 sRGB 颜色空间中计算 PSNR 和 SSIM 等评价指标。

3.4 RSblur

RSBlur 数据集包含成对的真实模糊图像及其相应的 ground truth 清晰图像。RSBlur 数据集可用于生成合成模糊图像，以便能够对真实和合成模糊之间的差异进行详细分析。训练集、验证集和测试集分别由 8,878、1,120 和 3,360 张模糊图像组成。

3.5 ReLoBlur

用于局部运动去模糊的 ReLoBlur 数据集包含 2405 张尺寸为 2152×1436 的模糊图像，其中 2010 张用于训练，395 张用于测试。该数据集由一对真实局部模糊图像和对应的清晰图像组成，这些图像由同步分光摄影系统获取。为了提高训练和测试效率，我们还提供了尺寸调整后的 ReLoBlur 数据集，其尺寸为 538×359 。

4.想法和思路

基于上述分析，本文进一步探讨在频域中引入极坐标表示，对模糊的方向性与频率衰减进行显式建模，并将其与深度网络结构相结合，以实现更有效的图像去模糊。

现有深度学习去模糊方法大多在空间域进行特征学习，通过加深网络或引入注意力机制来提升模型表达能力，但对运动模糊这一退化过程本身的建模相对隐式。尤其对于真实场景中的运动模糊，其退化往往具有明显的方向性和各向异性特征，仅依赖空间域卷积难以对不同方向、不同频率上的退化差异进行有效区分。

从经典成像理论角度看，线性运动模糊在频域中会表现出与运动方向相关

的各向异性频率响应，即不同方向和不同频率分量受到的衰减程度存在显著差异。这一特性在笛卡尔频域中较难直接刻画，而在极坐标频域表示下，可以自然地将退化拆分为方向维度和频率尺度维度，从而更清晰地反映模糊的结构特征。

基于上述观察，本工作的核心思路是：不直接在空间域中“猜测”模糊方向，而是利用频域极坐标表示显式建模各向异性退化特性，并将该信息用于指导图像恢复过程中的算子选择。具体而言，模型并不试图在整个网络中频繁进行频域计算，而是将频域极坐标分析作为一个退化建模与决策模块，引导空间域网络的恢复行为。




图 1 模型框架图

4.1 基于频域极坐标表示的运动模糊显式建模机制

针对现有频域去模糊方法多基于笛卡尔坐标系，导致方向信息与频率强度在二维平面内高度耦合、难以精准分离的问题，本文提出构建频域极坐标表示模块。利用极坐标空间天然的几何正交特性，模型将运动模糊的角向分布（对应运动方向）与径向分布（对应频率衰减）进行显式解耦。通过在特征层面将

笛卡尔频谱变换至极坐标空间，该机制能够从物理机理层面精准刻画模糊的各向异性特征与长距离依赖，克服了传统空域卷积网络难以显式捕捉复杂方向性退化的局限，为去模糊任务提供了一种符合成像机理的全新特征表示空间。

4.2 内容特征提取与退化模式感知相解耦的网络架构

区别于传统端到端网络将图像内容与退化特征混合编码的范式，本文设计了一种“诊断与治疗”分离的解耦架构。模型在编码器阶段专注于提取鲁棒的多尺度空间语义特征，避免在模糊模式尚不明确的早期阶段引入不可靠先验；同时，在深层特征空间构建独立的频域极坐标分析分支，专门负责对当前场景的模糊模式进行参数化描述。这种设计确保了网络能够独立、纯粹地解析模糊的结构化特征，不仅提升了模型对不同模糊类型的泛化能力，也为后续的图像复原提供了更精准的全局与局部退化描述符。

4.3 基于极坐标先验的不确定性感知动态路由复原

为解决频域先验在复杂非均匀模糊场景下可能失准的问题，本文摒弃了直接将频域特征用于重建的传统融合方式，提出了一种基于动态路由的软引导策略。该策略将极坐标频域信息转化为决策权重，通过调制解码器中的卷积算子自适应地控制复原过程。同时，引入不确定性感知机制，在模糊方向显著时增强频域引导，在模糊杂乱或极坐标特征置信度低时自动降低其权重。该策略有效实现了频域物理先验与空域数据驱动学习的互补，显著提升了模型在真实复杂场景下的鲁棒性与恢复效果。

4.4 基于极坐标特征空间的频域对比正则化机制

针对传统像素级损失函数（如 L1、MSE）倾向于平滑高频细节、导致复原图像纹理过平滑的问题，本文提出在频域极坐标特征空间引入对比学习约束。在 Bottleneck 或者 Decoder 输出特征上做对比。该机制利用极坐标表示对方向与频率的解耦特性，构建结构化的正负样本对：在潜在特征空间中，拉近复原图像与清晰基准图像在径向频率分布和角向几何特征上的距离，同时推开其与模糊输入图像的距离。通过这种显式的频域度量学习，强制网络关注高频分量的恢复与模糊方向的校正，从而在保证信噪比的同时，显著提升复原图像的感知质量与边缘锐度。

5.后续计划

2月：完成基准模型的代码实现，确保编码器-解码器主干与极坐标分支的数据流联通。

3月中旬前：进行初步的模型训练与调试，验证极坐标表示在提取模糊方向特征上的有效性，并调试频域对比学习损失函数的收敛稳定性，确立可行的 Baseline 模型。

4月：在主流数据集上跑对比实验，关注 PSNR、SSIM 指标的提升以及参数量/计算量（FLOPs）的平衡。

6月：做消融实验。

7月-8月：梳理实验数据，撰写论文。

6.总结

本文系统调研了近年来图像去模糊领域在空域建模、频域建模以及方向感知建模等方面的研究进展，并分析了现有方法在复杂运动模糊建模中的局限性。通过对成像机理与频域特性的分析，本文指出基于频域极坐标表示的方向显式建模具有进一步研究的潜力。后续工作可围绕极坐标频域表示与深度网络的高效融合展开，为复杂运动模糊场景下的图像去模糊提供新的解决思路。

参考文献

- [1] Bengio Y, Courville A, Vincent P. Representation Learning: A Review and New Perspectives[M]. arXiv, 2014[2026-01-23]. DOI:10.48550/arXiv.1206.5538.
- [2] Luo W, Li Y, Urtasun R, 等. Understanding the Effective Receptive Field in Deep Convolutional Neural Networks[C]//Advances in Neural Information Processing Systems: 卷 29. Curran Associates, Inc., 2016.
- [3] Ding X, Zhang X, Han J, et al. Scaling Up Your Kernels to 31x31: Revisiting Large Kernel Design in CNNs[J].
- [4] Zamir S W, Arora A, Khan S, et al. Restormer: Efficient Transformer for High-Resolution Image Restoration[C]//2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). New Orleans, LA, USA: IEEE, 2022: 5718-5729.
- [5] Kuo P H, Pan J, Chien S Y, 等. Efficient Concertormer for Image Deblurring and Beyond[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2025: 14665-14675.
- [6] Chen H, Wang Y, Guo T, et al. Pre-Trained Image Processing Transformer[C]//2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Nashville, TN, USA: IEEE, 2021: 12294-12305.
- [7] Wang Z, Cun X, Bao J, et al. Uformer: A General U-Shaped Transformer for Image Restoration[C]//2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). New Orleans, LA, USA: IEEE, 2022: 17662-17672.
- [8] Whyte O, Sivic J, Zisserman A, 等. Non-uniform deblurring for shaken images[C]//2010 IEEE Computer Society Conference on Computer Vision and Pattern Recognition. 2010: 491-498.
- [9] Chen L, Li Y, Dai J, 等. A Physics-Informed Blur Learning Framework for Imaging Systems[M]. arXiv, 2025[2026-01-23]. DOI:10.48550/arXiv.2502.11382.
- [10] Kong L, Dong J, Ge J, et al. Efficient Frequency Domain-based Transformers for High-Quality Image Deblurring[C]//2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Vancouver, BC, Canada: IEEE, 2023: 5886-5895.
- [11] Kong L, Dong J, Tang J, et al. Efficient Visual State Space Model for Image Deblurring[C]//CVPR 2025.
- [12] Jiao W, Li B, Shang W, et al. Efficient RAW Image Deblurring with Adaptive Frequency Modulation[J]. NeurIPS 2025.
- [13] Sun J, Wenfei Cao, Zongben Xu, et al. Learning a convolutional neural network for non-uniform motion blur removal[C]//2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Boston, MA, USA: IEEE, 2015: 769-777.
- [14] Gong D, Yang J, Liu L, et al. From Motion Blur to Motion Flow: A Deep Learning Solution for Removing Heterogeneous Motion Blur[C]//2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Honolulu, HI: IEEE, 2017: 3806-3815.
- [15] Wang L, Li Y, Wang S. DeepDeblur: Fast one-step blurry face images restoration[M]. arXiv, 2017[2026-01-20]. DOI:10.48550/arXiv.1711.09515.
- [16] Dong J, Pan J, Yang Z, et al. Multi-scale Residual Low-Pass Filter Network for Image Deblurring[C]//2023 IEEE/CVF International Conference on Computer Vision (ICCV). Paris, France: IEEE, 2023: 12311-12320.
- [17] Cho S J, Ji S W, Hong J P, et al. Rethinking Coarse-to-Fine Approach in Single

- Image Deblurring[C]//2021 IEEE/CVF International Conference on Computer Vision (ICCV). Montreal, QC, Canada: IEEE, 2021: 4621-4630.
- [18] Tao X, Gao H, Shen X, et al. Scale-Recurrent Network for Deep Image Deblurring[J].
 - [19] Zamir S W, Arora A, Khan S, et al. Multi-Stage Progressive Image Restoration[C]//2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Nashville, TN, USA: IEEE, 2021: 14816-14826.
 - [20] Zhang H, Dai Y, Li H, et al. Deep Stacked Hierarchical Multi-Patch Network for Image Deblurring[C]//2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Long Beach, CA, USA: IEEE, 2019: 5971-5979.
 - [21] Ruan L, Bemana M, Seidel H peter, et al. Revisiting Image Deblurring with an Efficient ConvNet[M]. arXiv, 2023[2026-01-20]. DOI:10.48550/arXiv.2302.02234.
 - [22] Ruan L, Bemana M, Seidel H peter, 等. Revisiting Image Deblurring with an Efficient ConvNet[EB/OL]. (2023-02-04)[2026-01-20]. <https://arxiv.org/abs/2302.02234v1>.
 - [23] Chen L, Chu X, Zhang X, 等. Simple Baselines for Image Restoration[M]. arXiv, 2022[2025-12-17]. DOI:10.48550/arXiv.2204.04676.
 - [24] Tsai F J, Peng Y T, Lin Y Y, et al. Stripformer: Strip Transformer for Fast Image Deblurring[M]//Avidan S, Brostow G, Cissé M, et al. Computer Vision – ECCV 2022: Vol. 13679. Cham: Springer Nature Switzerland, 2022: 146-162.
 - [25] Cheng H, Yang S, Zhou J T, et al. Frequency Guidance Matters in Few-Shot Learning[C]//2023 IEEE/CVF International Conference on Computer Vision (ICCV). Paris, France: IEEE, 2023: 11780-11790.
 - [26] Wang S, Veldhuis R, Brune C, et al. What do neural networks learn in image classification? A frequency shortcut perspective[C]//2023 IEEE/CVF International Conference on Computer Vision (ICCV). Paris, France: IEEE, 2023: 1433-1442.
 - [27] Yun G, Yoo J, Kim K, et al. SPANet: Frequency-balancing Token Mixer using Spectral Pooling Aggregation Modulation[C]//2023 IEEE/CVF International Conference on Computer Vision (ICCV). Paris, France: IEEE, 2023: 6090-6101.
 - [28] Wu W, Zhang X, Yin H, 等. FreDFT: Frequency Domain Fusion Transformer for Visible-Infrared Object Detection[M]. arXiv, 2025[2026-01-31]. DOI:10.48550/arXiv.2511.10046.
 - [29] Gao Z, Song J, Zhang Z, et al. Frequency-Guided Diffusion for Training-Free Text-Driven Image Translation[J].
 - [30] Liu C, Qi L, Pan J, et al. Frequency Domain-Based Diffusion Model for Unpaired Image Dehazing[J].
 - [31] Zhang H, Xie G, Li L, 等. Frequency-Domain Guided Swin Transformer and Global–Local Feature Integration for Remote Sensing Images Semantic Segmentation[J]. IEEE Transactions on Geoscience and Remote Sensing, 2025, 63: 1-11.
 - [32] Mao X, Liu Y, Liu F, et al. Intriguing Findings of Frequency Selection for Image Deblurring[M]. AAAI 2023 Oral, 2022[2025-12-19]. DOI:10.48550/arXiv.2111.11745.
 - [33] Mao X, Liu Y, Shen W, et al. Deep Residual Fourier Transformation for Single Image Deblurring[M]. arXiv, 2021[2026-01-17]. DOI:10.48550/arXiv.2111.11745.
 - [34] Zou W, Jiang M, Zhang Y, et al. SDWNet: A Straight Dilated Network with

- Wavelet Transformation for image Deblurring[C]//2021 IEEE/CVF International Conference on Computer Vision Workshops (ICCVW). Montreal, BC, Canada: IEEE, 2021: 1895-1904.
- [35] Lv X, Zhang S, Wang C, et al. Fourier Priors-Guided Diffusion for Zero-Shot Joint Low-Light Enhancement and Deblurring[C]//2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Seattle, WA, USA: IEEE, 2024: 25378-25388.
 - [36] Zhu Q, Zhou M, Zheng N, et al. Exploring Temporal Frequency Spectrum in Deep Video Deblurring[C]//2023 IEEE/CVF International Conference on Computer Vision (ICCV). Paris, France: IEEE, 2023: 12394-12403.
 - [37] Gao X, Qiu T, Zhang X, et al. Efficient Multi-Scale Network with Learnable Discrete Wavelet Transform for Blind Motion Deblurring[C]//2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Seattle, WA, USA: IEEE, 2024: 2733-2742.
 - [38] Liu L, Liu J, Yuan S, et al. Wavelet-Based Dual-Branch Network for Image Demoiré'ing[J].
 - [39] Hu X, Zhu L, Fu C W, et al. Direction-Aware Spatial Context Features for Shadow Detection[C]//2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Salt Lake City, UT, USA: IEEE, 2018: 7454-7462.
 - [40] Guo H, Li J, Dai T, 等. MambaIR: A Simple Baseline for Image Restoration with State-Space Model[EB/OL]. (2024-02-23)[2025-11-27]. <https://arxiv.org/abs/2402.15648v3>.
 - [41] Xu Y, Ju J, Luan J, 等. Direction-Aware Diagonal Autoregressive Image Generation[M]. arXiv, 2025[2026-01-31]. DOI:10.48550/arXiv.2503.11129.
 - [42] Weiler M, Cesa G. General SE(2)-Equivariant Steerable CNNs[M]. arXiv, 2021[2026-01-31]. DOI:10.48550/arXiv.1911.08251.
 - [43] Liu C X, Wang X, Xu X, et al. Motion-Adaptive Separable Collaborative Filters for Blind Motion Deblurring[C]//2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Seattle, WA, USA: IEEE, 2024: 25595-25605.
 - [44] Fang Z, Wu F, Dong W, et al. Self-supervised Non-uniform Kernel Estimation with Flow-based Motion Prior for Blind Image Deblurring[C]//2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Vancouver, BC, Canada: IEEE, 2023: 18105-18114.
 - [45] Chen D, Zhou S, Pan J, et al. A Polarization-Aided Transformer for Image Deblurring via Motion Vector Decomposition[J].
 - [46] Fang Z, Wu F, Huang T, et al. Parameterized Blur Kernel Prior Learning for Local Motion Deblurring[J].
 - [47] Ji X, Wang Z, Satoh S, et al. Single Image Deblurring with Row-dependent Blur Magnitude[C]//2023 IEEE/CVF International Conference on Computer Vision (ICCV). Paris, France: IEEE, 2023: 12235-12246.
 - [48] Rim J, Lee H, Won J, et al. Real-World Blur Dataset for Learning and Benchmarking Deblurring Algorithms[M]//Vedaldi A, Bischof H, Brox T, et al. Computer Vision – ECCV 2020: Vol. 12370. Cham: Springer International Publishing, 2020: 184-201.
 - [49] Shen Z, Wang W, Lu X, et al. Human-Aware Motion Deblurring[C]//2019 IEEE/CVF International Conference on Computer Vision (ICCV). Seoul, Korea (South): IEEE, 2019: 5571-5580.
 - [50] Rim J, Kim G, Kim J, 等. Realistic Blur Synthesis for Learning Image

- Deblurring[M]. arXiv, 2022[2026-01-29]. DOI:10.48550/arXiv.2202.08771.
- [51] Nah S, Kim T H, Lee K M. Deep Multi-scale Convolutional Neural Network for Dynamic Scene Deblurring[C]//2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Honolulu, HI: IEEE, 2017: 257-265.